TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA

Difesa Adversarial per Sistemi di Rilevamento delle Intrusioni di Rete basati su Modelli di Deep Learning: un Approccio Layer-wise

Tesi di Laurea Magistrale in Ingegneria Informatica

Alessandro Finocchi

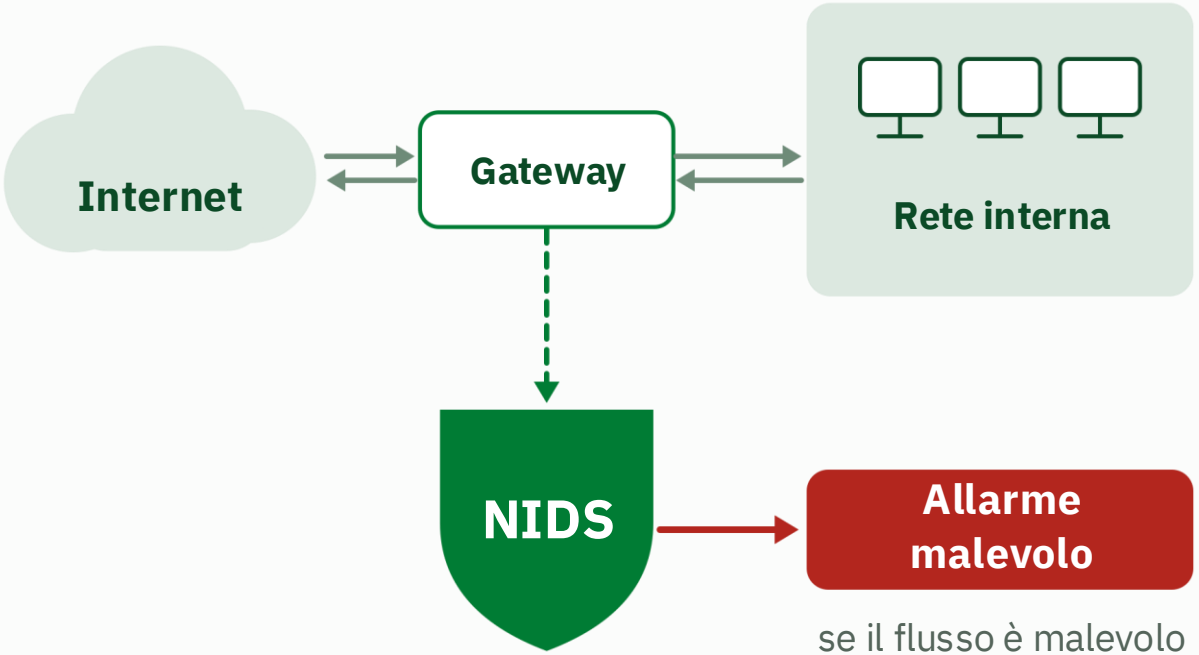
Laureando · matricola 0340543

Relatore: Dott. Gabriele Russo Russo

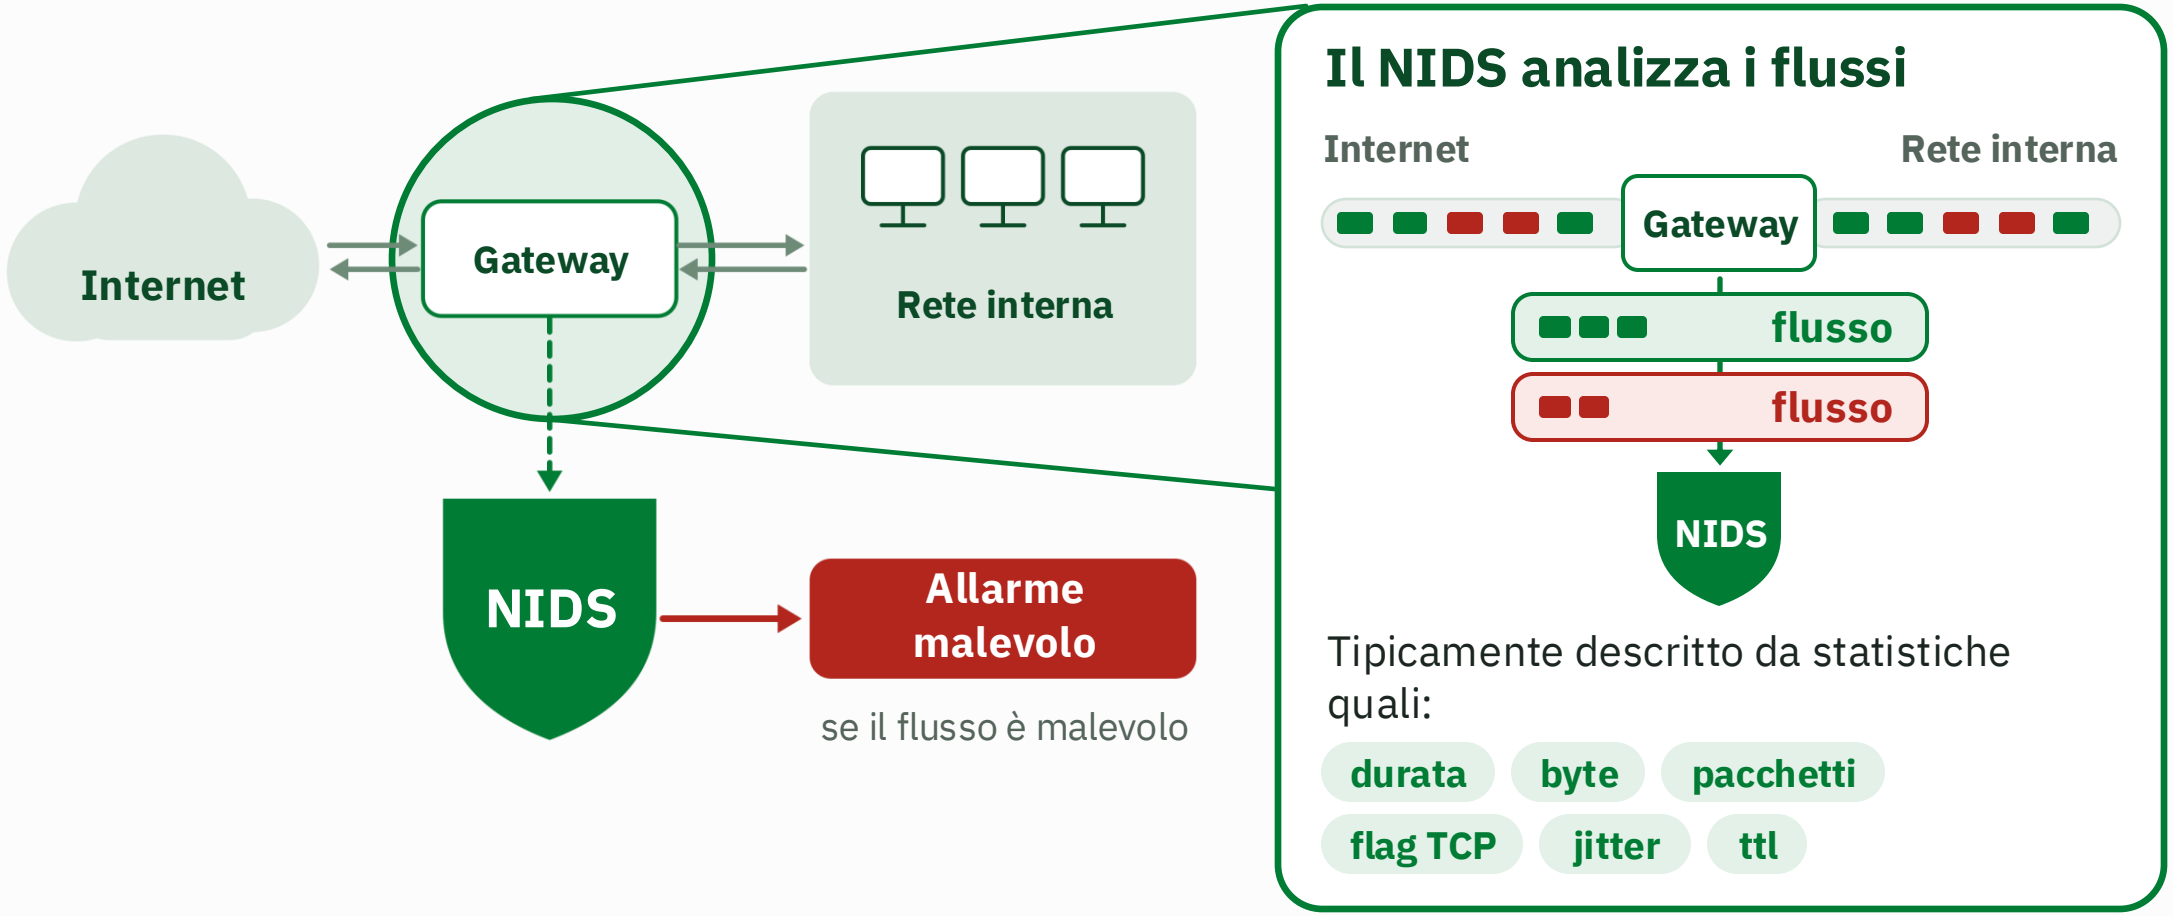
Correlatore: Prof. Giuseppe Bianchi

Università degli Studi di Roma Tor Vergata · Macroarea di Ingegneria · Anno Accademico 2025/2026

NIDS: il network intrusion detection system



NIDS: il network intrusion detection system



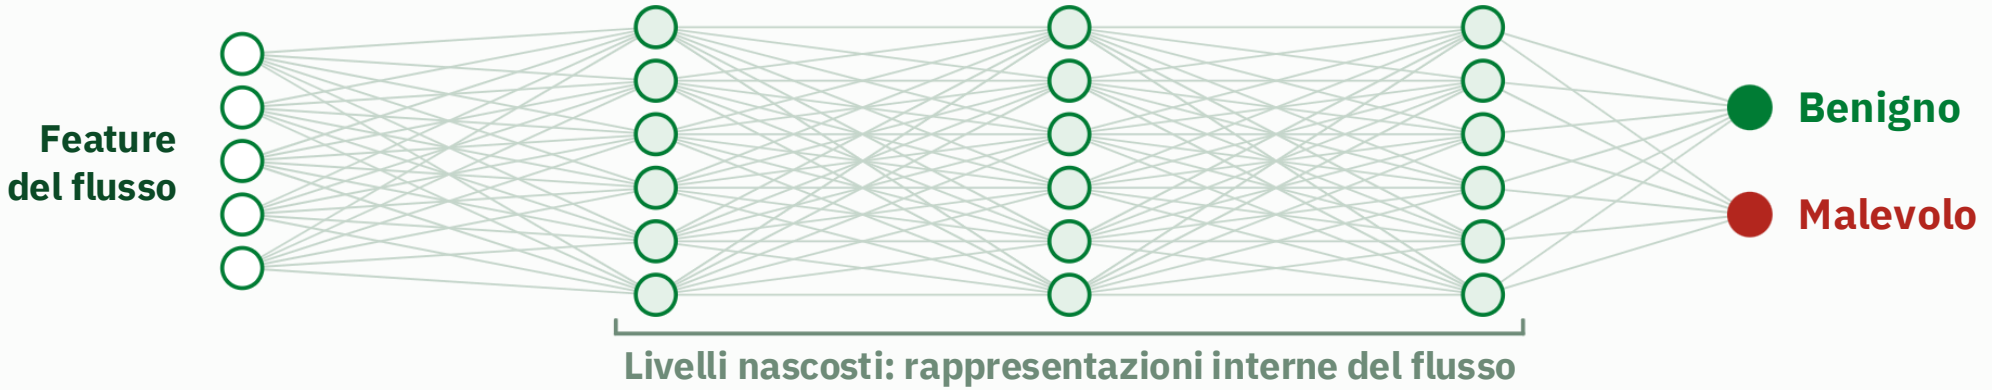
NIDS: la transizione al Deep Learning

Sistemi a firme

Confrontano il traffico con un archivio di attacchi noti, ciechi contro gli attacchi nuovi (zero-day)

Deep Learning

Imparano dai dati i pattern del traffico malevolo, con accuratezze oltre il 98% sui benchmark



Attacchi adversarial: cosa sono

Dominio delle immagini



Originale
→ «STOP»

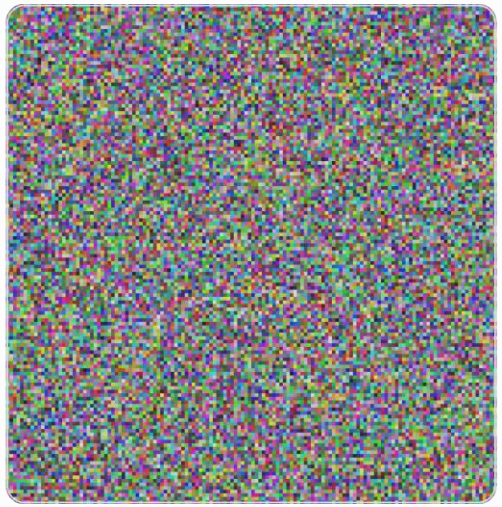
Attacchi adversarial: cosa sono

Dominio delle immagini



Originale
→ **«STOP»**

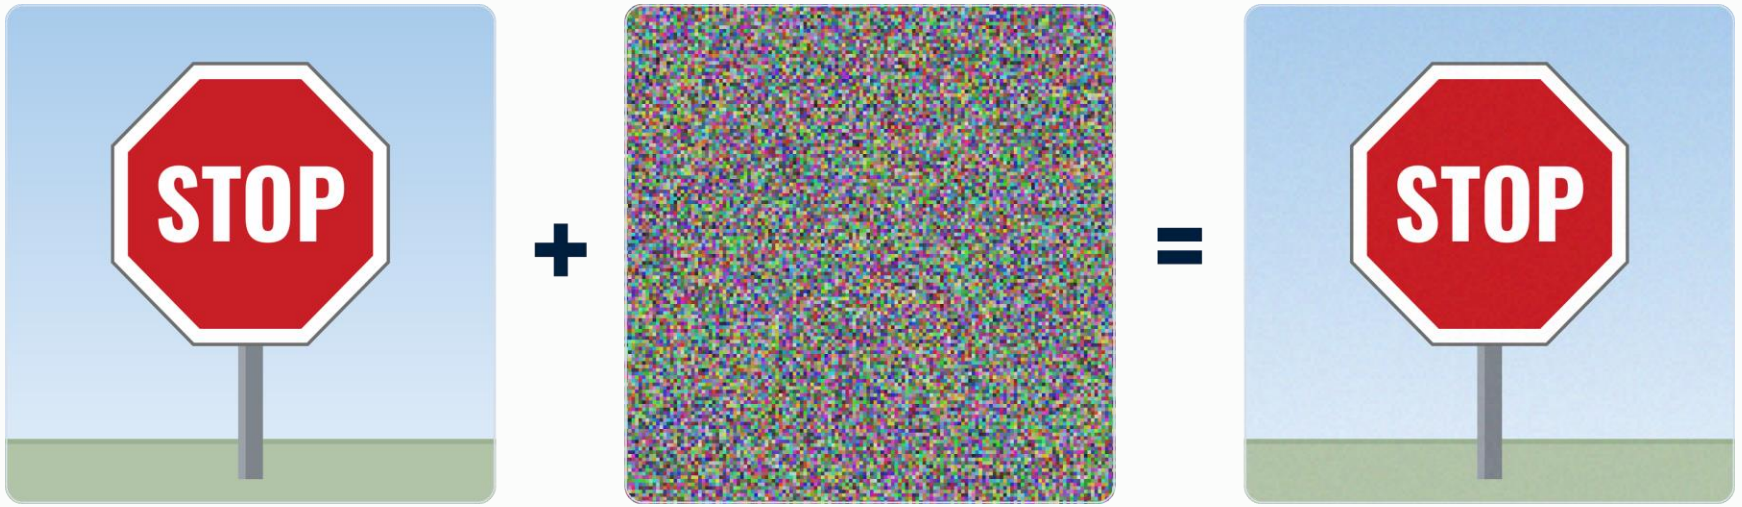
+



Perturbazione opportuna e impercettibile

Attacchi adversarial: cosa sono

Dominio delle immagini



Originale
→ **«STOP»**

Perturbazione opportuna e impercettibile

Adversarial
→ **«limite di velocità»**

Attacchi adversarial: cosa sono

Dominio dei NIDS

Flusso pulito

durata

byte

pacchetti

NIDS: malevolo → allarme

Attacchi adversarial: cosa sono

Dominio dei NIDS

Flusso pulito

durata
byte
pacchetti

NIDS: malevolo → allarme

+ perturbazione δ

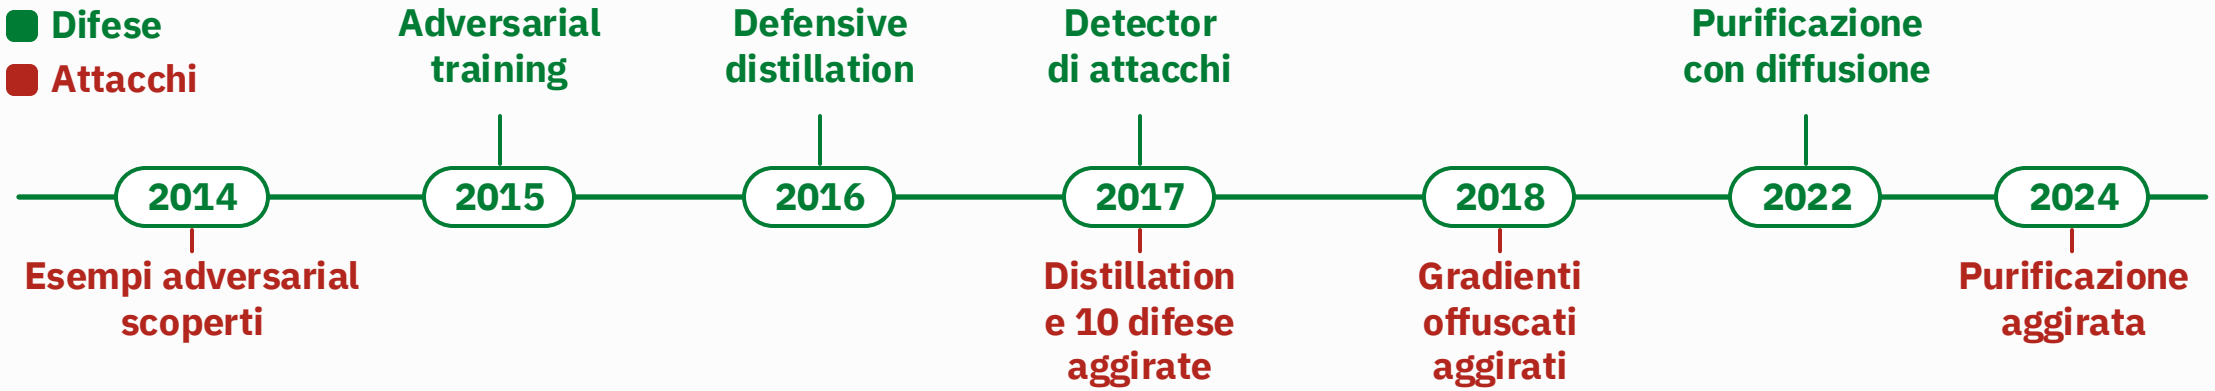
piccola: entro un budget ε

Flusso adversarial

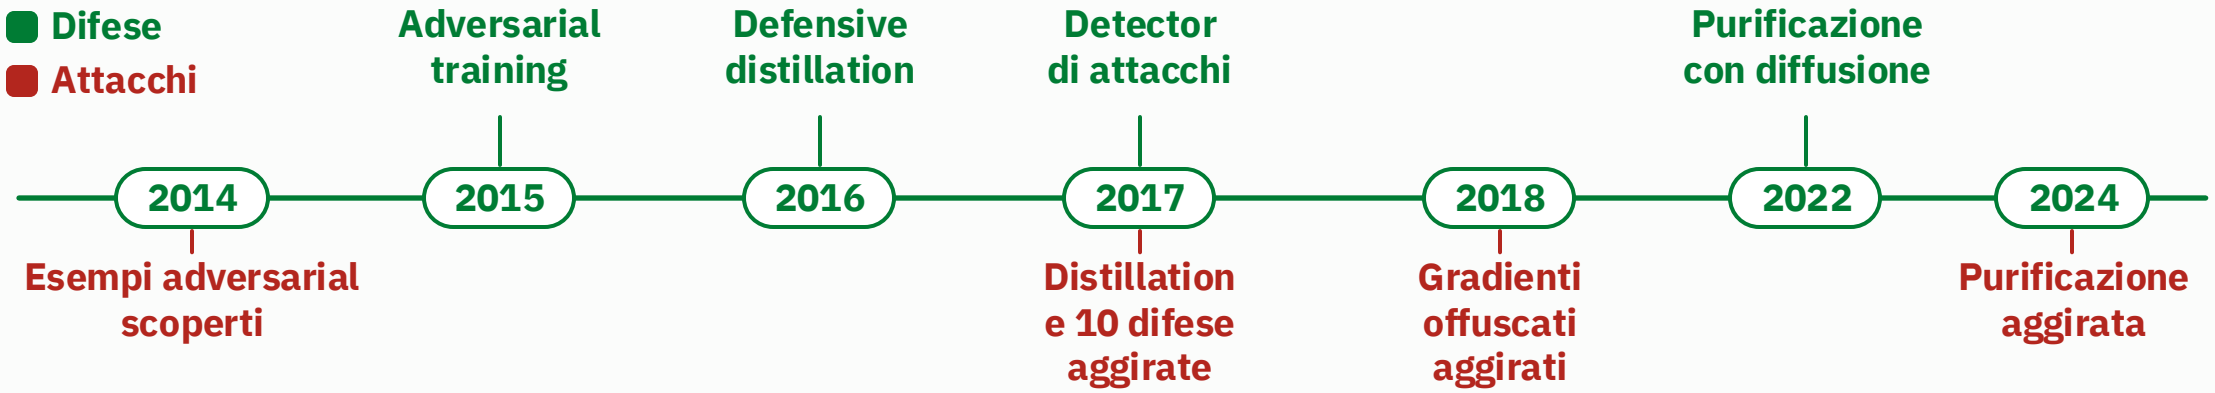
durata
byte
pacchetti

NIDS: benigno → nessun allarme

Attacchi adversarial: stato dell'arte



Attacchi adversarial: stato dell'arte



Evidenziate le due famiglie su cui lavora la tesi

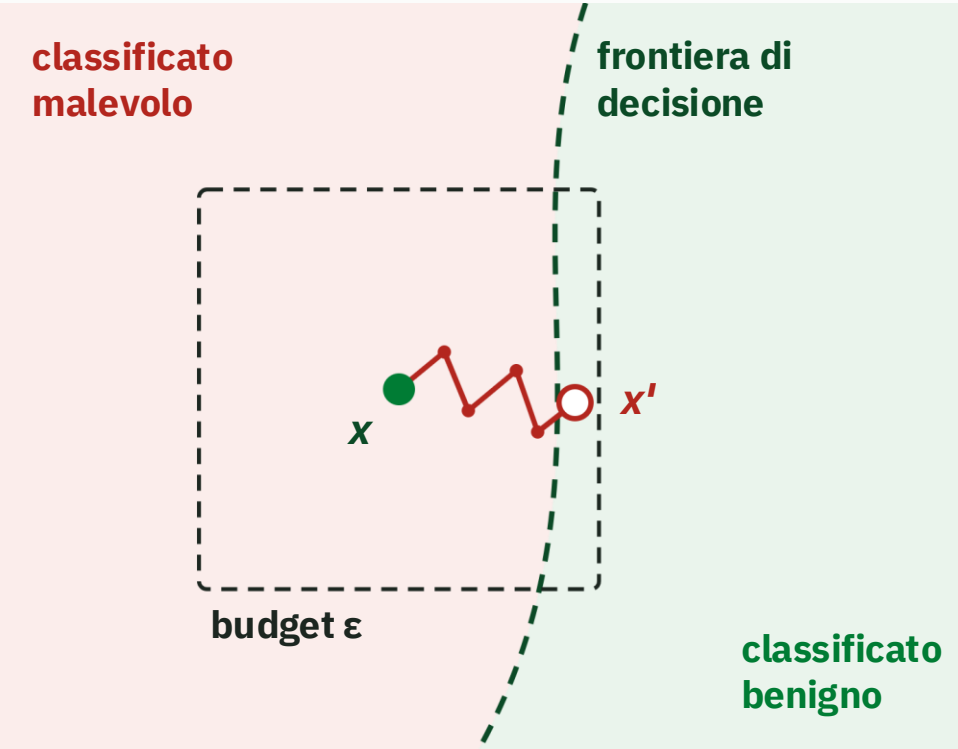
Adversarial training
Training robusto

Robustezza certificata
Garanzie formali

Purificazione
Ripulisce l'input

Rilevamento
Rileva e rifiuta

Attacchi adversarial: come funzionano



Modello di minaccia White-box

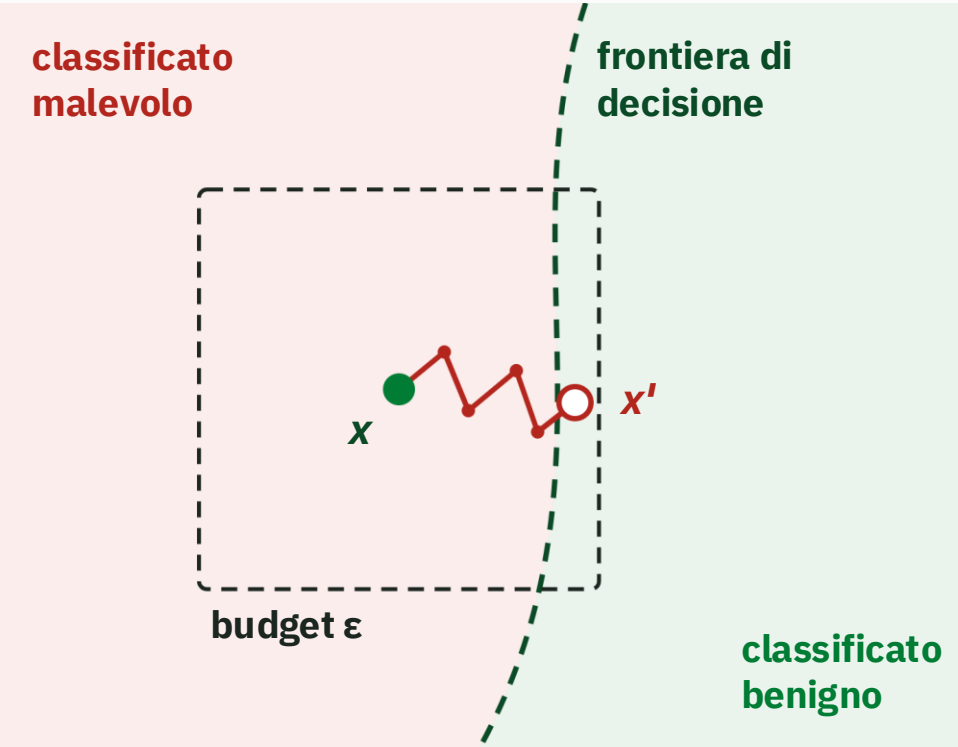
PGD

Tanti piccoli passi, sempre dentro il budget ε: è l'attacco universale al primo ordine

PGD adattivo

Inganna il classificatore (massimizzando l'errore) e, contemporaneamente, abbassa lo score dei detector

Attacchi adversarial: come funzionano



Training: Discesa del gradiente

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \alpha \cdot \nabla_{\boldsymbol{\theta}} \mathcal{L}(f(\boldsymbol{x}, \boldsymbol{\theta}), y)$$

Attacco: Ascesa del gradiente

$$\boldsymbol{x} \leftarrow \boldsymbol{x} + \alpha \cdot \nabla_{\boldsymbol{x}} \mathcal{L}(f(\boldsymbol{x}, \boldsymbol{\theta}), y)$$

Obiettivi della tesi

1. Misurare

quanto l'attacco sposta le attivazioni di ogni livello nascosto

Metrica SLAV per livello

Obiettivi della tesi

1. Misurare

quanto l'attacco sposta le attivazioni di ogni livello nascosto

Metrica SLAV per livello

2. Difendere

la rete rilevando l'attacco sfruttando le attivazioni dei livelli interni

Detector multi-livello

Obiettivi della tesi

1. Misurare

quanto l'attacco sposta le attivazioni di ogni livello nascosto

Metrica SLAV per livello

2. Difendere

la rete rilevando l'attacco sfruttando le attivazioni dei livelli interni

Detector multi-livello

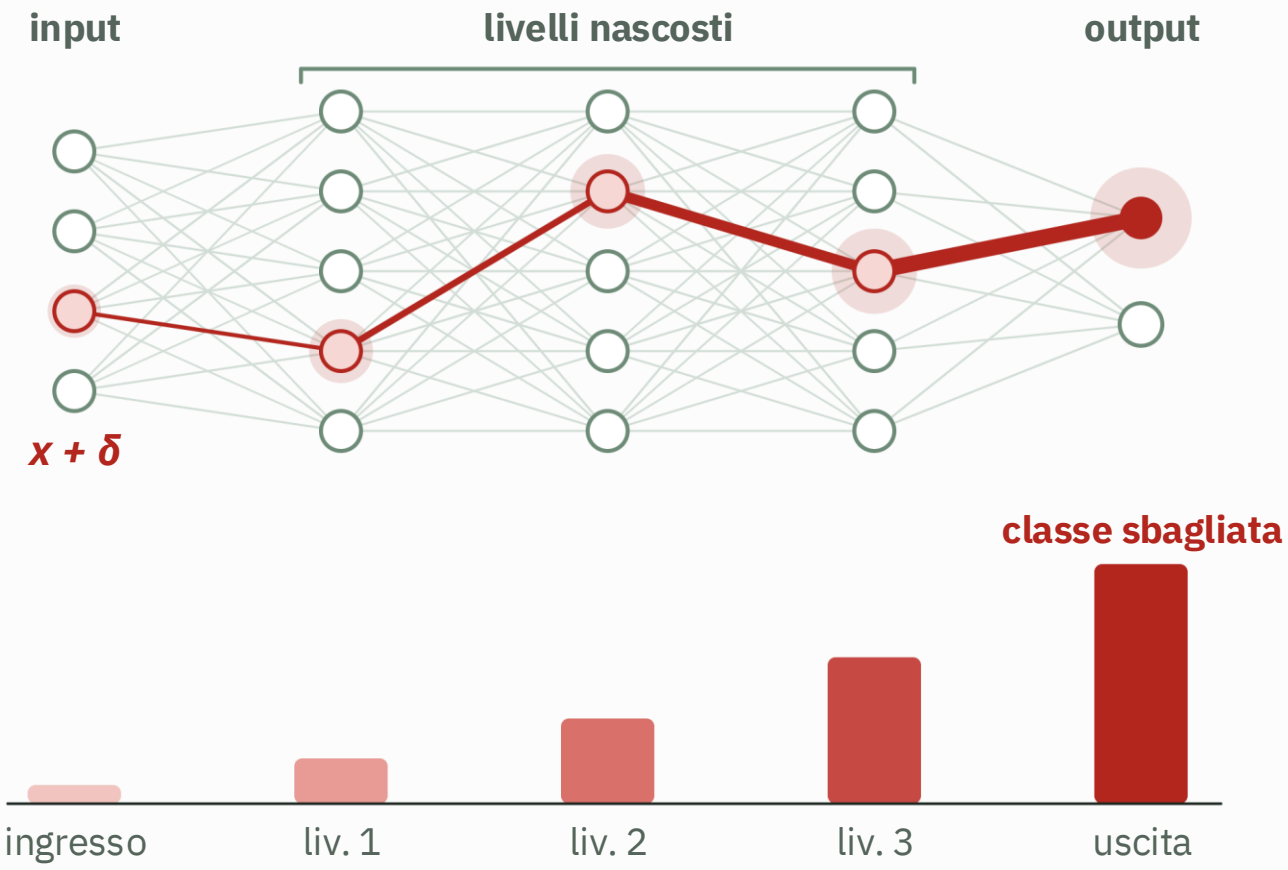
3. Evolvere

le difese attuali modellando le rappresentazioni dei livelli interni attraverso la SLAV

Manipolazione di livelli

Effetto della perturbazione

Obiettivo • Misurare

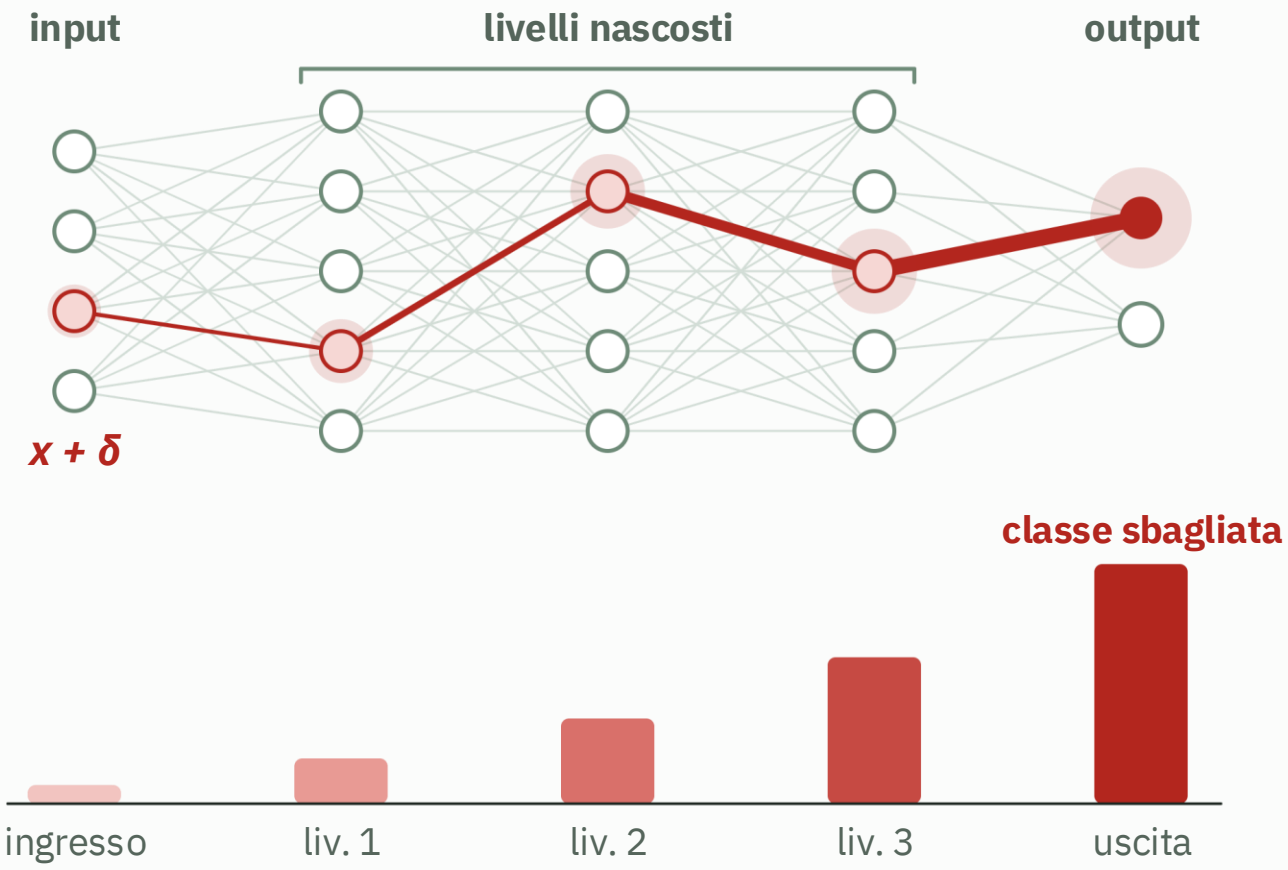


Trasformata
Una piccola variazione cambia di livello in livello

Osservabile
La deviazione è visibile nei livelli interni, prima dell'uscita

Effetto della perturbazione

Obiettivo • Misurare



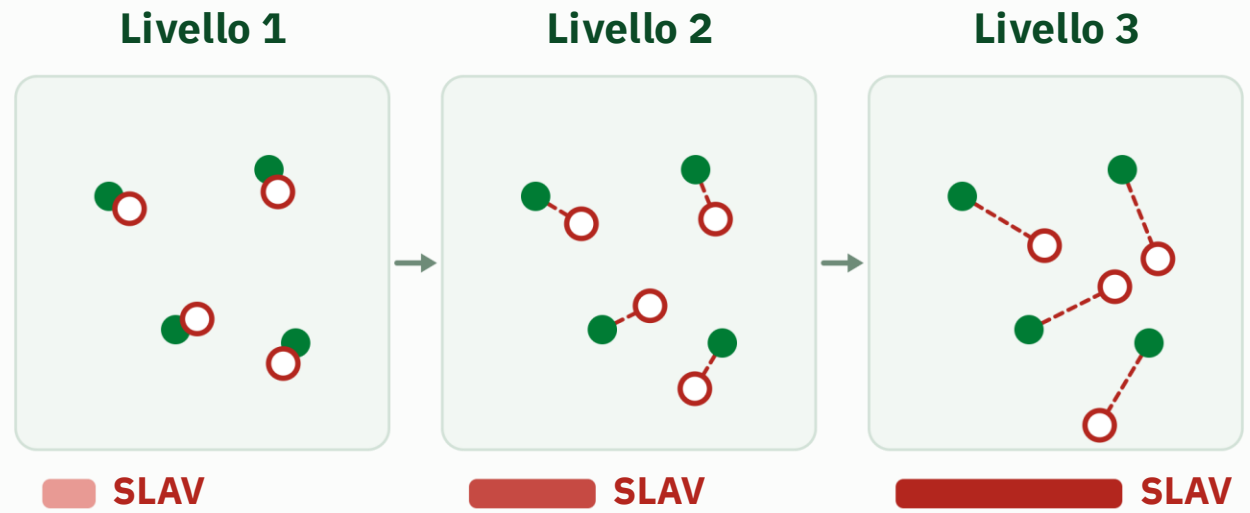
Trasformata
Una piccola variazione cambia di livello in livello

Osservabile
La deviazione è visibile nei livelli interni, prima dell'uscita

Idea: guardare dentro la rete, non solo la sua uscita

Metrica di vulnerabilità per livello

Obiettivo • Misurare



Distanza media tra le rappresentazioni del flusso pulito e flusso adversarial

pulito adversarial

1 Stesso flusso, due versioni

Si confrontano le rappresentazioni del flusso pulito con la sua versione adversarial

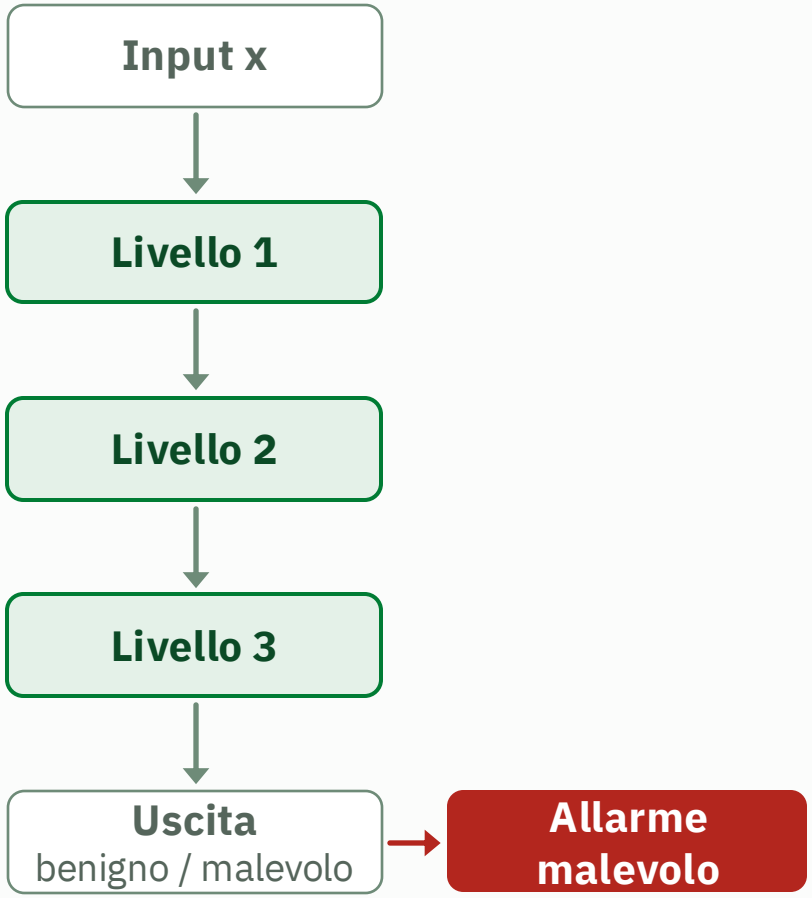
2 Una misura per livello

Normalizzata sulla larghezza per essere confrontabile tra livelli

$$s^{(l)}(x, x^{adv}) = \frac{1}{d_l} \|a^{(l)}(x^{adv}) - a^{(l)}(x)\|_2^2$$

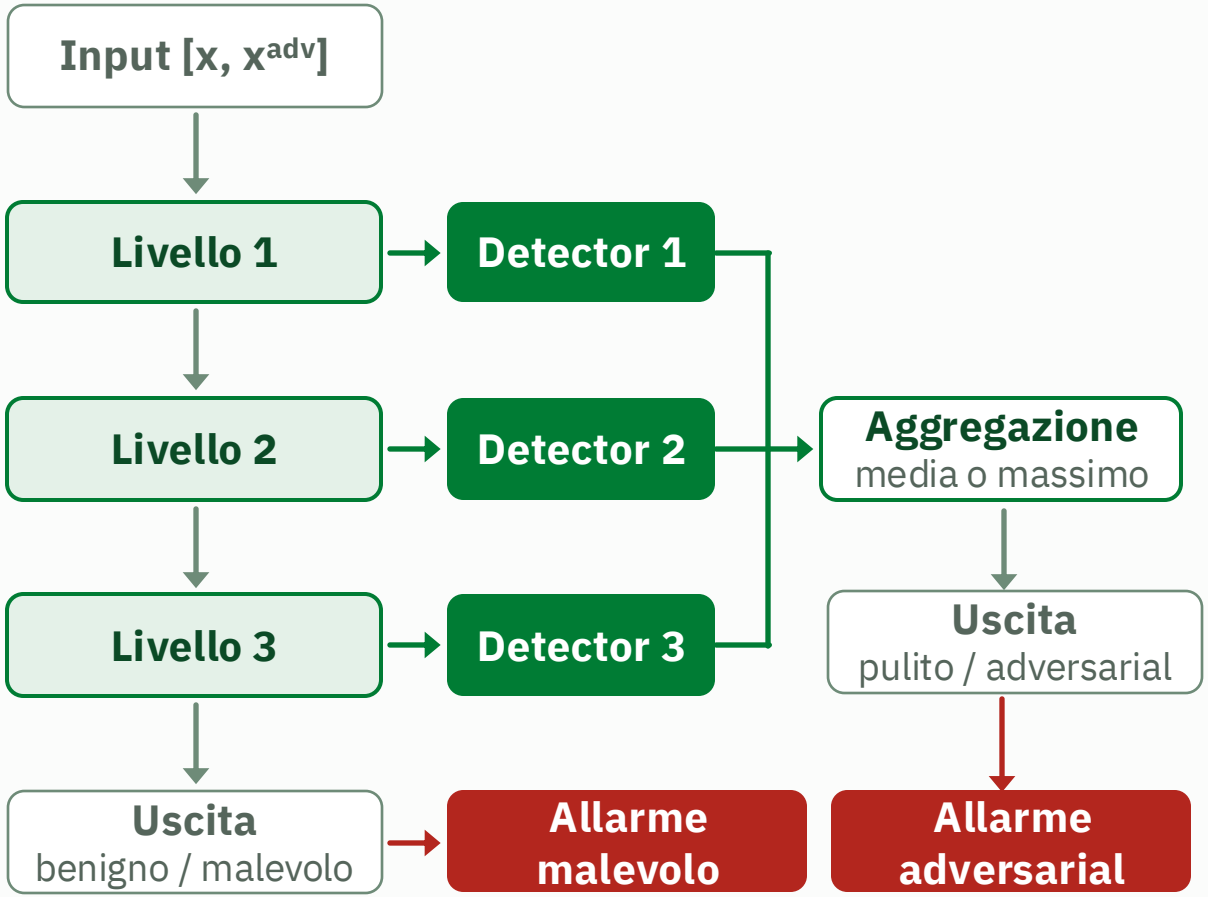
Meccanismo di rilevamento

Obiettivo • Difendere



Meccanismo di rilevamento

Obiettivo • Difendere



Addestramento congiunto

Unica backpropagation per backbone e detector

Batch misto

Flussi puliti + versioni adversarial

Aggregazione degli score

Voto democratico o dittatoriale

Modellare la geometria dei livelli

Obiettivo • Evolvere

CloserAL · attrattiva

Avvicina le attivazioni

Obiettivo: migliorare l'adversarial training

FurtherAL · repulsiva

Allontana le attivazioni

Obiettivo: attacco più visibile al detector

pulito adversarial

Modellare la geometria dei livelli

Obiettivo • Evolvere

CloserAL · attrattiva

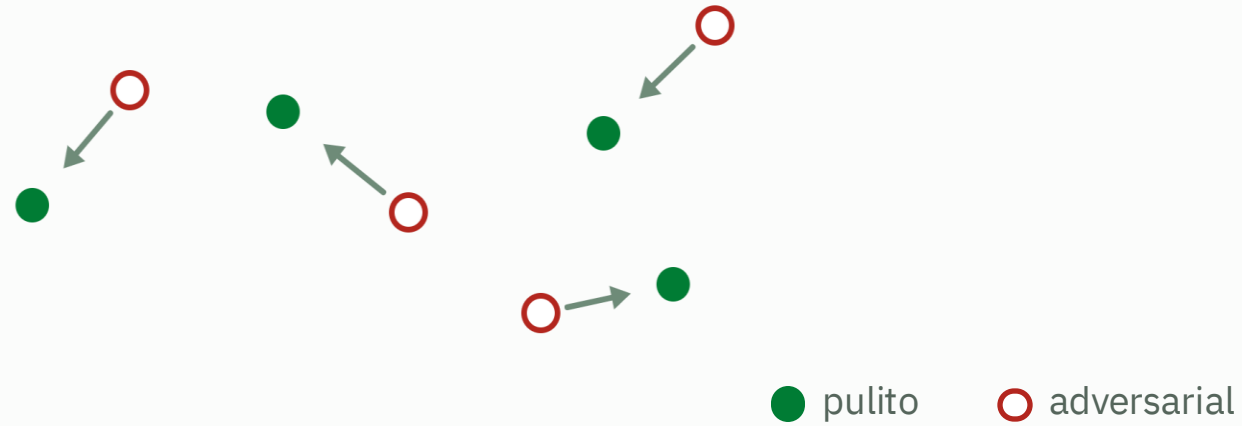
Avvicina le attivazioni

Obiettivo: migliorare l'adversarial training

FurtherAL · repulsiva

Allontana le attivazioni

Obiettivo: attacco più visibile al detector



Modellare la geometria dei livelli

Obiettivo • Evolvere

CloserAL · attrattiva

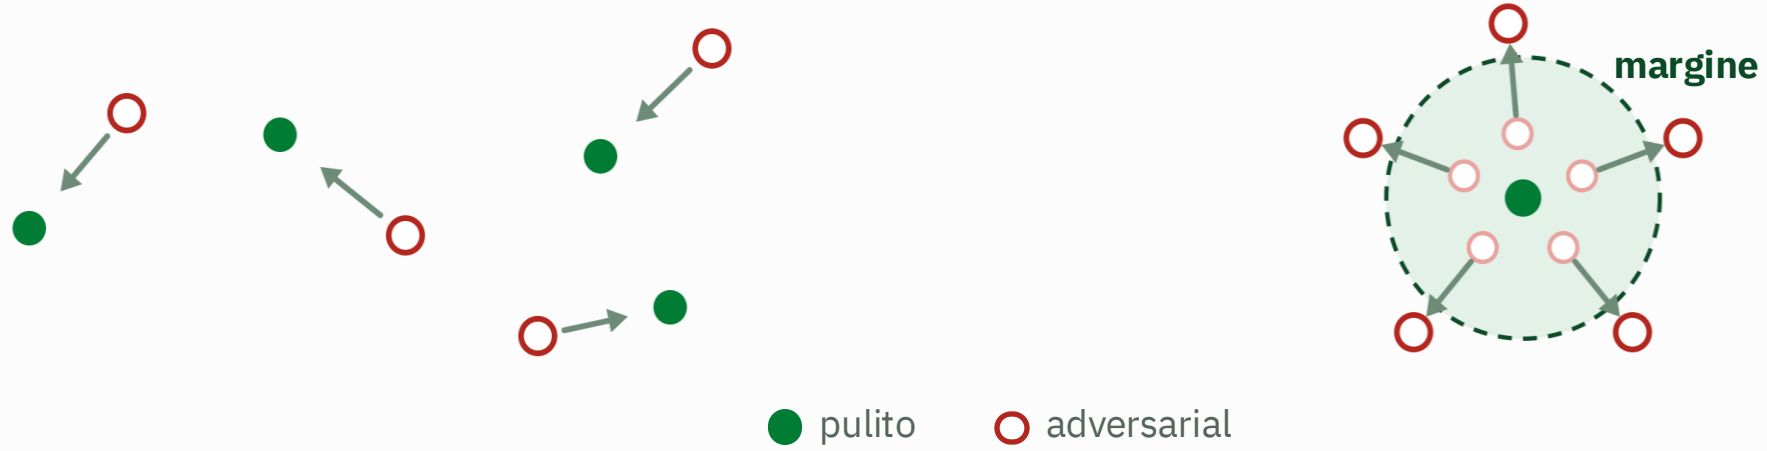
Avvicina le attivazioni

Obiettivo: migliorare l'adversarial training

FurtherAL · repulsiva

Allontana le attivazioni

Obiettivo: attacco più visibile al detector



Valutazione: stadi della sperimentazione

1

Baseline e V&V

valori di riferimento e suite di test

Valutazione: stadi della sperimentazione

1

Baseline e V&V

valori di riferimento e suite di test

2

Architetture

121 configurazioni per dataset

Valutazione: stadi della sperimentazione

1

Baseline e V&V

valori di riferimento e suite di test

2

Architetture

121 configurazioni per dataset

3

Detection

come regolare il funzionamento dei detector

Valutazione: stadi della sperimentazione

1

Baseline e V&V

valori di riferimento e suite di test

2

Architetture

121 configurazioni per dataset

3

Detection

come regolare il funzionamento dei detector

4

Pesi della loss

regola i termini di addestramento

Valutazione: stadi della sperimentazione

1

Baseline e V&V

valori di riferimento e suite di test

2

Architetture

121 configurazioni per dataset

3

Detection

come regolare il funzionamento dei detector

4

Pesi della loss

regola i termini di addestramento

5

Caso peggiore

attacchi più forti con parametri diversi

Valutazione: stadi della sperimentazione

1 **Baseline e V&V**
valori di riferimento e suite di test

→

2 **Architetture**
121 configurazioni per dataset

→

3 **Detection**
come regolare il funzionamento dei detector

→

4 **Pesi della loss**
regola i termini di addestramento

→

5 **Caso peggiore**
attacchi più forti con parametri diversi

4 Dataset pubblici

Benchmark di riferimento, tutti preprocessati allo stesso modo

Implementazione in PyTorch open source

github.com/AlessandroFinocchi/lw_aml_detector

Valutazione: metrica esperimenti

La backbone **classifica** il flusso come benigno o malevolo, il detector può dare **l'allarme adversarial**.

Flusso pulito

	nessun allarme	allarme adversarial
classe corretta	successo	falso allarme
classe errata	errore	errore

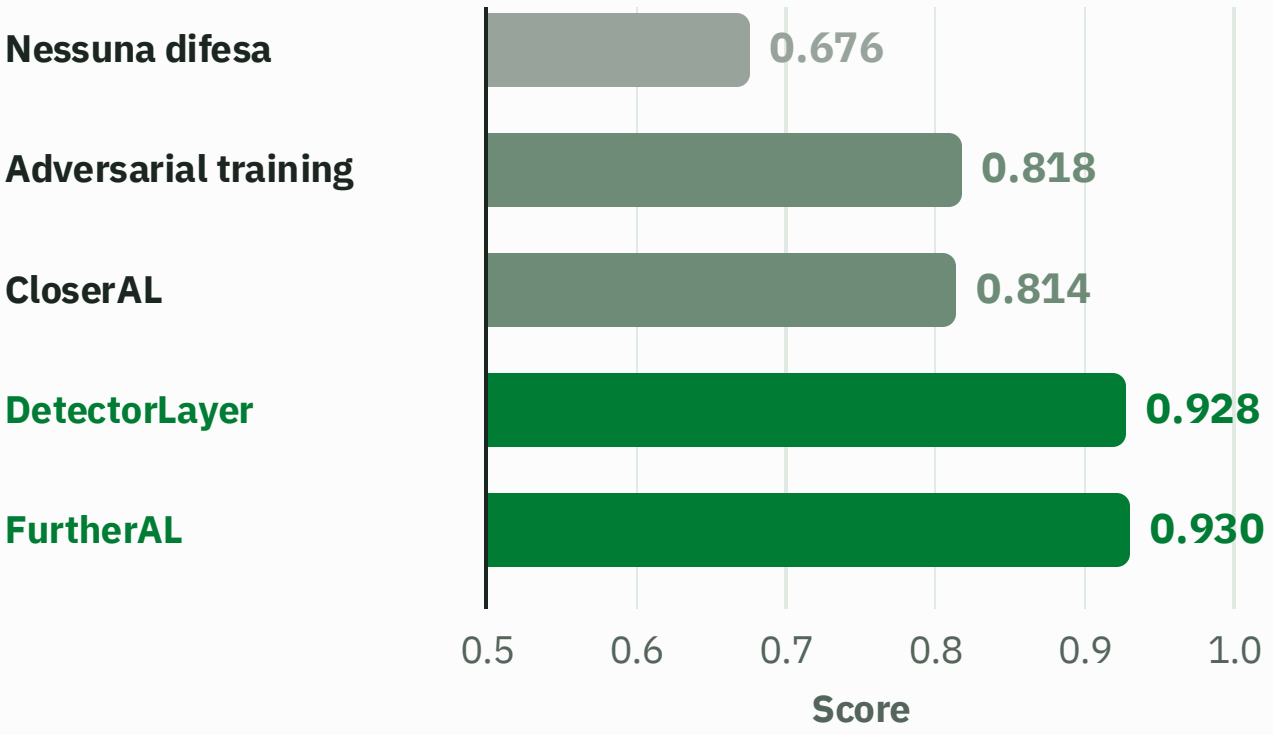
Flusso adversarial

	nessun allarme	allarme adversarial
classe corretta	resiste	segnalato
classe errata	eluso	segnalato

Score = ½ · (accuratezza pulita + accuratezza adversarial)

Valutazione: contro l'attacco di addestramento

Score di test · Dataset UNSW-NB15



> 99.5%

degli attacchi segnalati dall'allarme

≈ 0.5%

falsi allarmi su traffico pulito

+0.11

di Score rispetto al miglior modello senza detector (0.818)

Valutazione: dove si rileva meglio la perturbazione

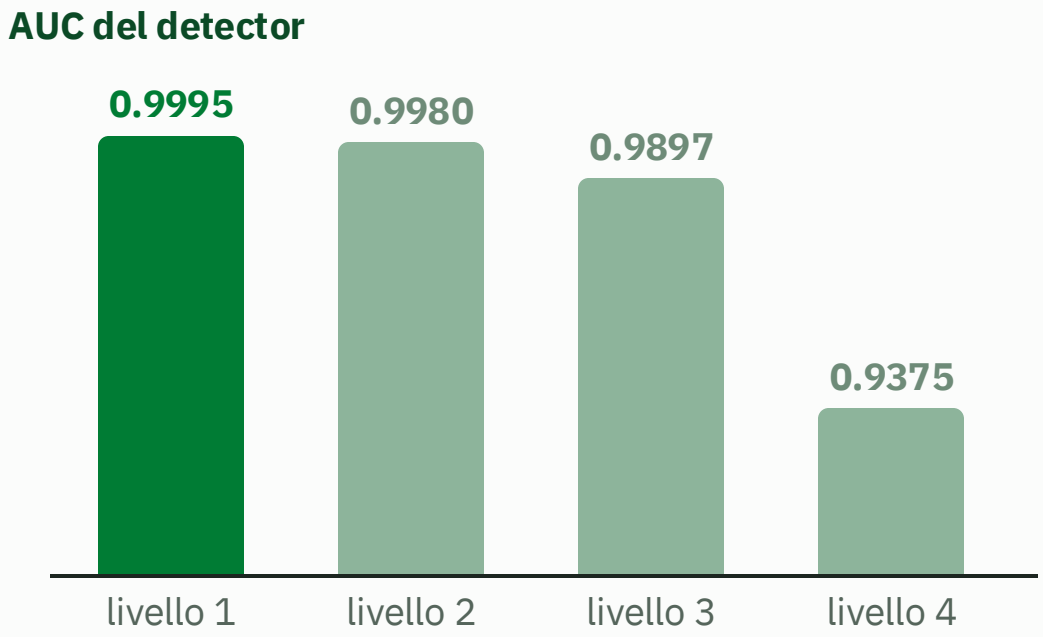
Deviazione (SLAV) per livello



Ipotesi di partenza

Più deviazione in profondità: i detector degli ultimi livelli dovrebbero essere i migliori

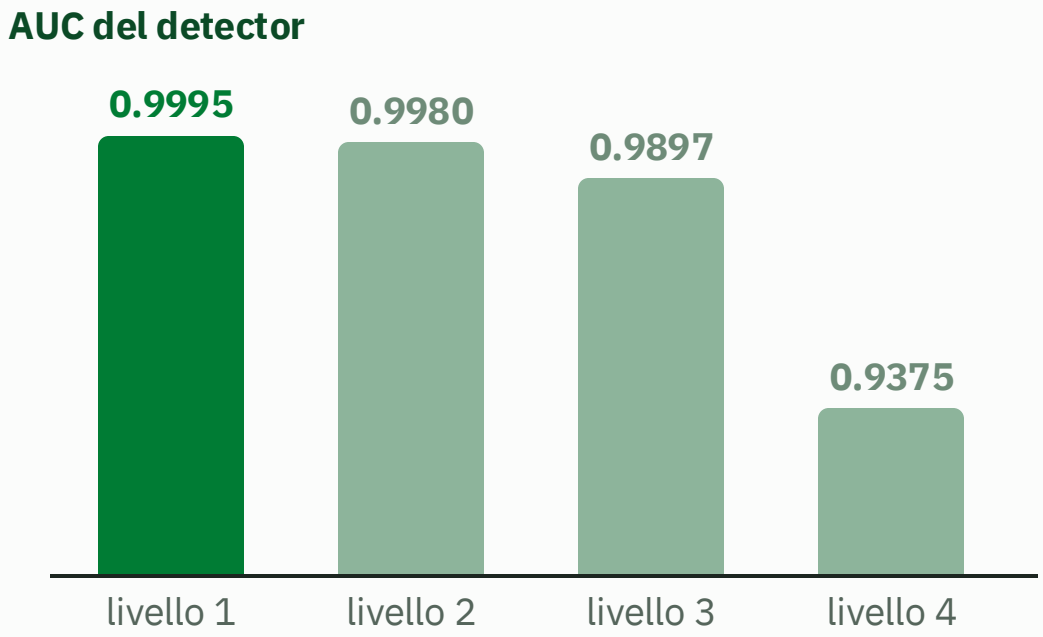
Valutazione: dove si rileva meglio la perturbazione



Una possibile causa

La deviazione amplificata spinge le attivazioni oltre molteplici frontiere decisionali

Valutazione: dove si rileva meglio la perturbazione



Una possibile causa

La deviazione amplificata spinge le attivazioni oltre molteplici frontiere decisionali

Un detector sul primo livello è indispensabile: senza, lo Score perde fino a 0.07

Valutazione: l'effetto delle strategie geometriche

CloserAL · attrattiva

Rispetto all'adversarial training

SLAV livello 1	**÷ 3.9**
SLAV livello 2	**÷ 29.6**
Liv. 2 e 3 non estesi con il primo esteso	**÷ 2 · ÷ 1.2**
Accuratezza backbone contro PGD	**0.808 → 0.811**
Score PGD	**0.854 → 0.854**

FurtherAL · repulsiva

Rispetto a DetectorLayer

SLAV livello 1	**× 8.1**
SLAV livello 2	**× 4.6**
Liv. 2 e 3 non estesi con il primo esteso	**× 3.3 · × 2.4**
Accuratezza backbone contro PGD	**0.150 → 0.395**
Score PGD adattivo	**0.930 → 0.897**

Valutazione: l'effetto delle strategie geometriche

CloserAL · attrattiva

Rispetto all'adversarial training

SLAV livello 1	**÷ 3.9**
SLAV livello 2	**÷ 29.6**
Liv. 2 e 3 non estesi con il primo esteso	**÷ 2 · ÷ 1.2**
Accuratezza backbone contro PGD	**0.808 → 0.811**
Score PGD	**0.854 → 0.854**

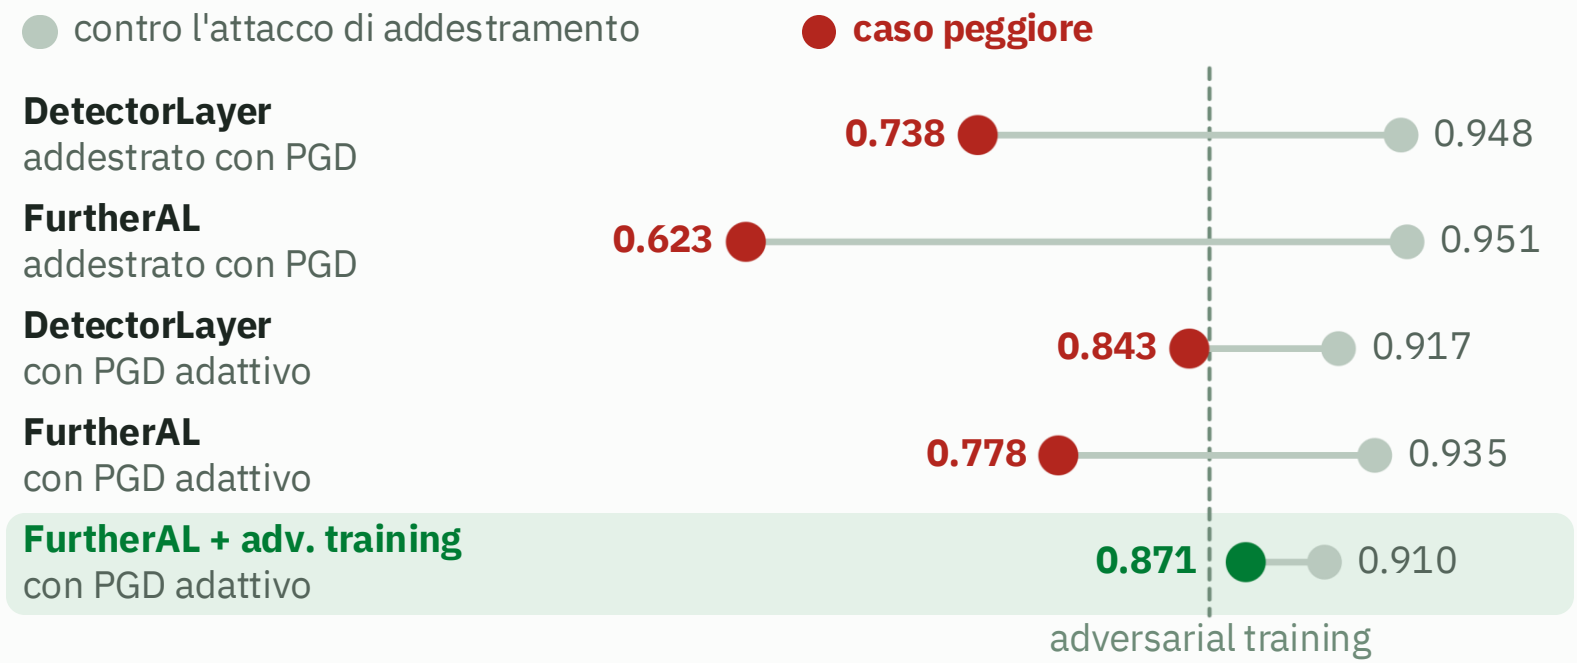
FurtherAL · repulsiva

Rispetto a DetectorLayer

SLAV livello 1	**× 8.1**
SLAV livello 2	**× 4.6**
Liv. 2 e 3 non estesi con il primo esteso	**× 3.3 · × 2.4**
Accuratezza backbone contro PGD	**0.150 → 0.395**
Score PGD adattivo	**0.930 → 0.897**

La repulsione separa davvero; l'attrazione invece non migliora lo Score

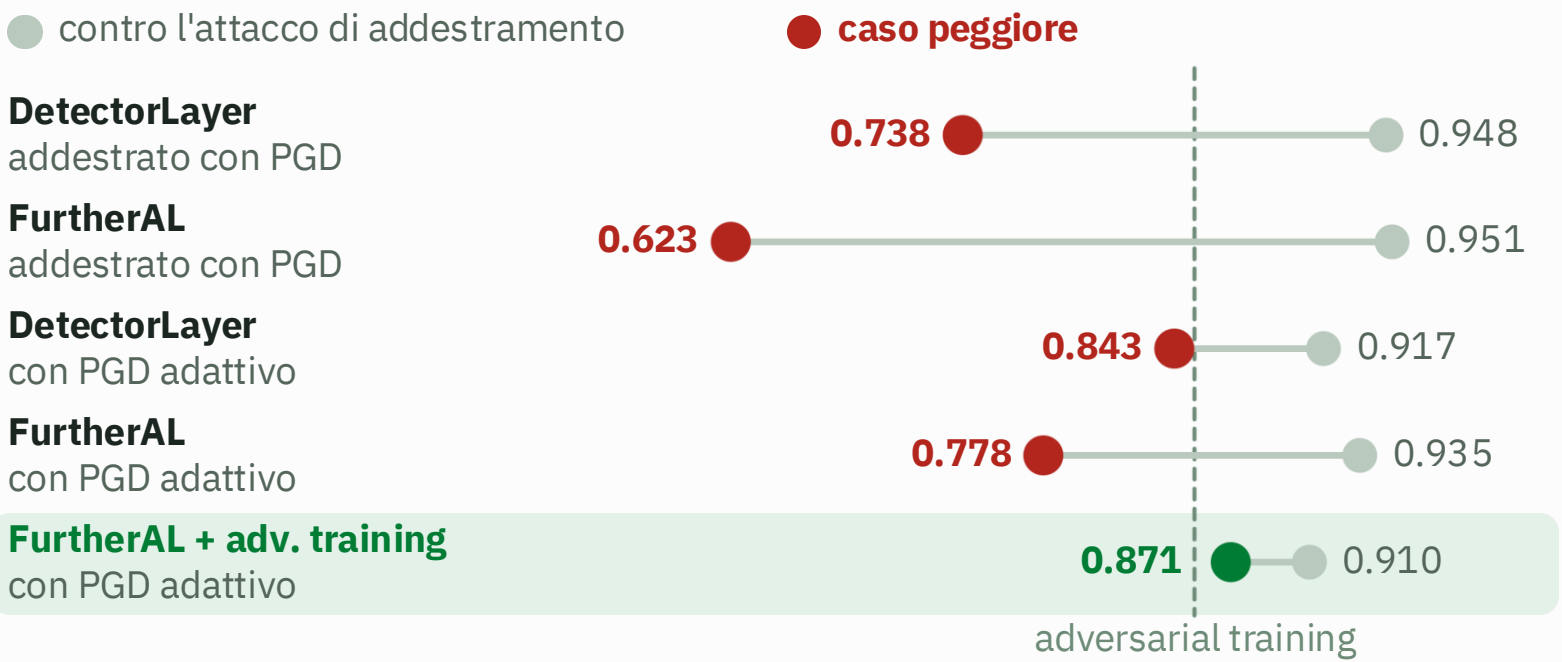
Valutazione: caso peggiore



> 90%

dei campioni elude i detector addestrati con PGD

Valutazione: caso peggiore



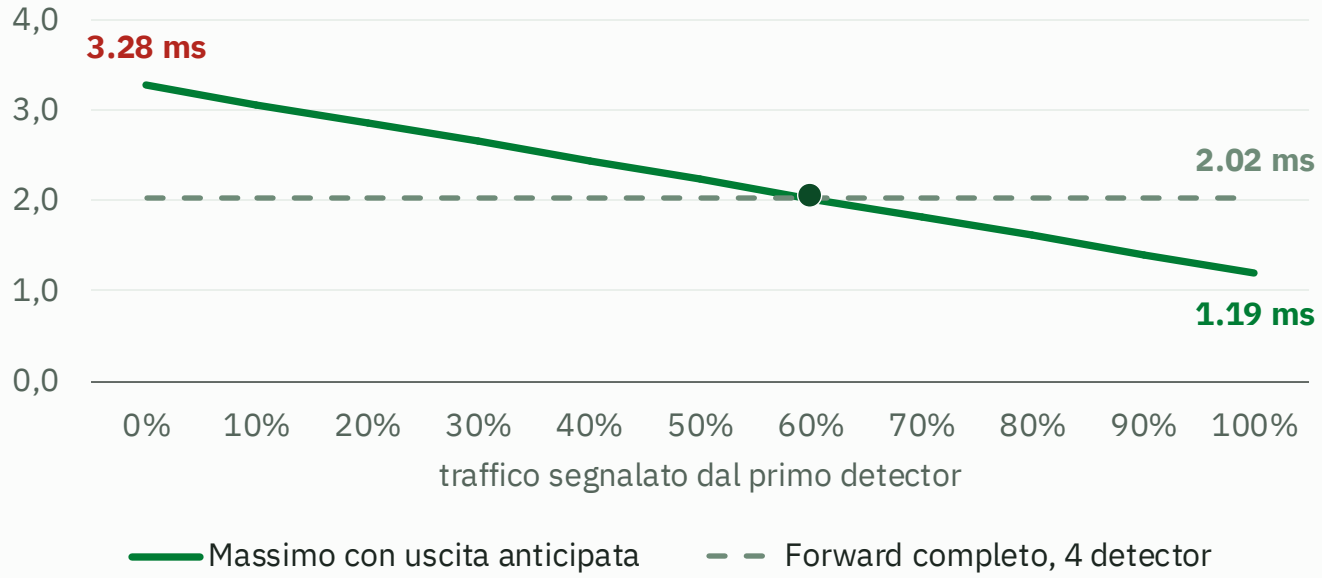
> 90%

dei campioni elude i detector addestrati con PGD

Conta il passo dell'attacco: per eludere l'allarme serve una ricerca fine

Valutazione: latenza con uscita anticipata

Latenza media per campione (ms) · 4 detector, UNSW-NB15



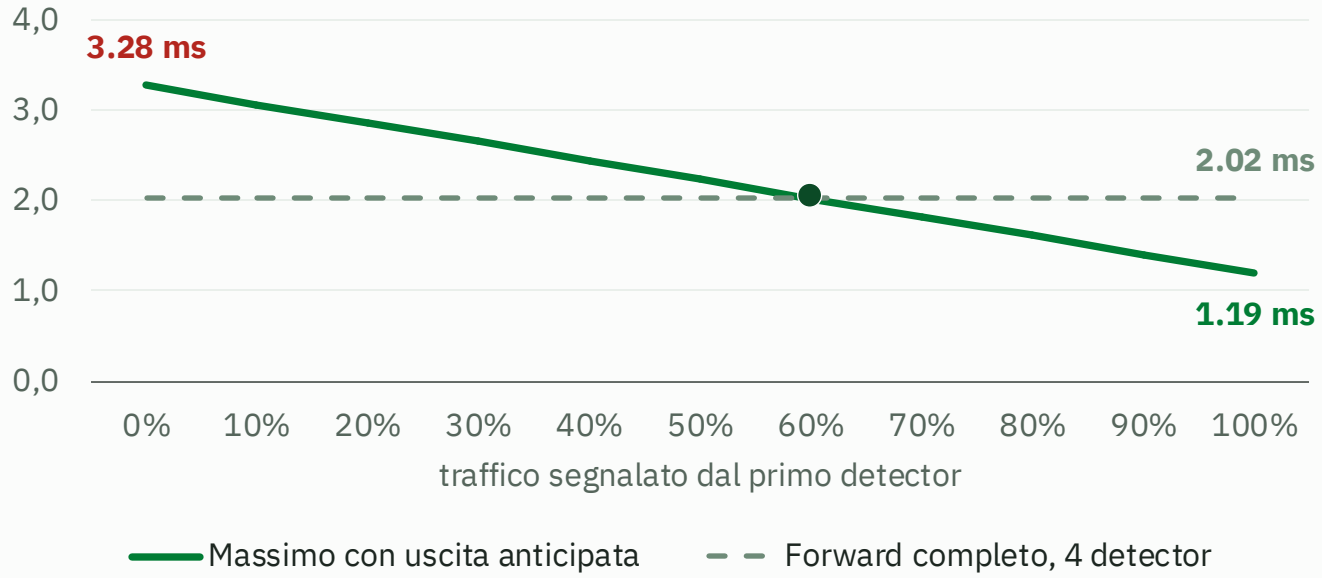
−43% se esce al 1° detector

+60% se non esce

Pareggio a circa il 60%

Valutazione: latenza con uscita anticipata

Latenza media per campione (ms) · 4 detector, UNSW-NB15



−43% se esce al 1° detector

+60% se non esce

Pareggio a circa il 60%

L'uscita anticipata riduce la latenza solo in ambienti altamente adversarial

Conclusioni e sviluppi futuri

Risultati

- La perturbazione si rileva meglio nel primo livello nascosto
- La combinazione FurtherAL + adversarial training è la combinazione più robusta
- Valutare i detector con attacchi adattivi dai parametri esplorati

Sviluppi futuri

- Vincoli di dominio e di budget per ogni feature
- Detector con una visione congiunta dei livelli
- Irrobustire modelli già esistenti

TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA

Grazie per l'attenzione

Domande?

alessandro.finocchi@alumni.uniroma2.eu